

# **Estudo sobre a Violência contra a mulher no Brasil**

Study on violence against women in Brazil

## **Resumo:**

A violência contra a mulher constitui uma das mais graves violações dos direitos humanos conforme a Conferência das Nações Unidas sobre Direitos Humanos da Onu em Viena em 1993 proclamou, analisando o contexto principal da figura da mulher na sociedade brasileira torna-se enfático como milhões de brasileiras em diferentes contextos sociais, econômicos e culturais são afetadas. Este estudo tem como objetivo analisar o cenário da violência contra a mulher no Brasil, citando seus principais tipos, fatores associados, perfil das vítimas e dos agressores, como os desafios enfrentados no combate a essa problemática. A pesquisa utiliza como base revisão bibliográfica e análise de dados estatísticos provenientes de órgãos oficiais, como o Fórum Brasileiro de Segurança Pública, o Instituto de Pesquisa Econômica Aplicada e o Ministério da Justiça. Os resultados evidenciam que a violência física e psicológica se destaca com recorrência, sendo praticada majoritariamente por parceiros ou ex-parceiros das vítimas. Observa-se ainda que fatores como desigualdade de gênero, dependência econômica, vulnerabilidade social e naturalização da violência contribuem significativamente para a persistência desse fenômeno. Apesar dos avanços legislativos, especialmente com a promulgação da Lei Maria da Penha e da Lei do Feminicídio, ainda existem obstáculos relacionados à subnotificação, à insuficiência de políticas públicas e às barreiras de acesso à rede de proteção. Conclui-se que o enfrentamento à violência contra a mulher exige ações integradas entre Estado, sociedade civil e instituições, visando à promoção da igualdade de gênero, ao fortalecimento dos mecanismos de denúncia e à garantia de proteção efetiva às vítimas.

**Palavras-chave:** Violência; Mulher; Direitos Humanos.

## **Abstract:**

Violence against women constitutes one of the most serious violations of human rights, as proclaimed by the United Nations Conference on Human Rights held in Vienna in 1993. An analysis of the broader context of women's roles in Brazilian society highlights how millions

of Brazilian women across diverse social, economic, and cultural backgrounds are affected. This study aims to analyze the landscape of violence against women in Brazil, highlighting its main types, associated factors, and the profiles of victims and perpetrators, as well as the challenges faced in combating this issue. The research is based on a literature review and analysis of statistical data from official agencies, such as the Brazilian Forum on Public Safety, the Institute of Applied Economic Research, and the Ministry of Justice. The results show that physical and psychological violence are the most common forms, perpetrated primarily by the victims' partners or former partners. It is also observed that factors such as gender inequality, economic dependence, social vulnerability, and the normalization of violence contribute significantly to the persistence of this phenomenon. Despite legislative advances, particularly with the enactment of the Maria da Penha Law and the Femicide Law, obstacles remain related to underreporting, insufficient public policies, and barriers to accessing the protection network. It can be concluded that combating violence against women requires coordinated action among the government, civil society, and institutions, with the aim of promoting gender equality, strengthening reporting mechanisms, and ensuring effective protection for victims.

**Key-words:** Violence; Women; Human Rights.

## **INTRODUÇÃO**

A violência contra a mulher representa uma das mais graves violações dos direitos humanos no Brasil e no mundo, constituída pela Organização das Nações Unidas (ONU) por meio da Declaração sobre a Eliminação da Violência contra as Mulheres, adotada pela Assembleia Geral através da Resolução nº 48/104 de 20 de dezembro de 1993. Trata-se de um fenômeno social histórico e estrutural que transcende fronteiras geográficas, classes sociais, níveis educacionais e contextos culturais. Dado o contexto histórico brasileiro, essa problemática surge em evidência por proporções alarmantes, via dados coletados pelo SINAN (Sistema de Informações de Agravos de Notificação), impactando diretamente a segurança, dignidade, saúde física e mental, bem como a autonomia das mulheres. Neste sentido, a declaração criada por meio da ONU, torna-se fundamental para proteção e eliminação da violência contra as mulheres, que pode comprometer não somente a vida das vítimas, mas também o desenvolvimento social e econômico dos países.

### **Fundamentação Internacional dos Direitos das Mulheres**

A ONU reconhece, há décadas, que a violência contra a mulher constitui um obstáculo à igualdade, ao desenvolvimento e à paz, decorrido pela relação de poder historicamente desiguais entre homens e mulheres. A Declaração sobre a Eliminação da Violência contra as Mulheres, adotada pela Assembleia Geral das Nações Unidas em 1993, estabelece que essa violência representa uma violação direta dos direitos humanos e das liberdades fundamentais, impedindo que mulheres exerçam plenamente seus direitos em condições de igualdade. Esse reconhecimento consolidou a compreensão de que o enfrentamento à violência de gênero é uma responsabilidade compartilhada entre Estados, instituições e sociedade civil.

### **Perspectiva Histórica e Social**

Segundo a ONU a violência contra as mulheres decorre de relações historicamente desiguais de poder entre homens e mulheres. Essas desigualdades estruturais sustentam práticas de dominação, discriminação e subordinação feminina, perpetuando ciclos de violência ao longo das gerações. Nesse sentido, a violência não deve ser compreendida como um fenômeno isolado ou meramente individual, mas como uma manifestação de padrões sociais e culturais profundamente enraizados nas relações de gênero.

## **Contexto Brasileiro**

No Brasil, a violência contra a mulher permanece ativamente como um dos maiores tipos de violência práticas, onde o Brasil permanece no Top 5 dos países com maior taxa de violência contra a mulher, segundo pesquisa da ONU. Dados recentes apontam crescimento no número de mulheres que declaram ter sofrido algum tipo de violência, servindo como alarme da persistência do problema, ainda em crescimento, e o fortalecimento dos mecanismos de denúncia e conscientização social. A violência doméstica e familiar destaca-se como uma das formas mais recorrentes.

## **Marco Legal e Institucional**

No cenário nacional, a promulgação da Lei Maria da Penha (Lei Nº 11.340/2006) sancionada em 7 de agosto de 2006 representou um marco fundamental na proteção dos direitos das mulheres, estabelecendo mecanismos específicos de prevenção, assistência e responsabilização dos agressores. Complementarmente, o Conselho Nacional da Justiça desempenha papel fundamental na articulação de políticas públicas, campanhas educativas e iniciativas voltadas ao enfrentamento da violência de gênero no âmbito do Poder Judiciário.

## **REVISÃO BIBLIOGRÁFICA**

A violência contra a mulher é reconhecida pela literatura científica como um fenômeno social complexo, relacionado a fatores históricos, culturais e estruturais que ultrapassam a esfera individual. Sob a perspectiva dos estudos de gênero, a violência é compreendida como resultado de relações desiguais de poder entre homens e mulheres, construídas e reproduzidas ao longo do tempo.

Segundo pesquisas da área de Psicologia Social, a violência de gênero está associada à naturalização de comportamentos de dominação masculina e à manutenção de estruturas patriarcais que historicamente posicionaram as mulheres em condições de vulnerabilidade social. Nessa perspectiva, a violência não deve ser compreendida apenas como um ato isolado praticado por determinados indivíduos, mas como uma manifestação de desigualdades estruturais presentes na sociedade.

O artigo publicado na revista *Psicologia & Sociedade* destaca que a violência contra a mulher está diretamente relacionada a processos históricos de naturalização da desigualdade de gênero, reforçando mecanismos de dominação e controle sobre o corpo, a autonomia e a liberdade feminina. Dessa forma, a violência de gênero constitui um fenômeno social que exige abordagens multidisciplinares para sua compreensão e enfrentamento.

Um dos principais desafios enfrentados por pesquisadores e gestores públicos é a subnotificação dos casos de violência contra a mulher. Diversos estudos apontam que parte significativa das vítimas não formaliza denúncias devido ao medo de represálias, dependência econômica, vínculos afetivos com o agressor, vergonha ou falta de confiança nos mecanismos institucionais de proteção.

A literatura demonstra que os registros oficiais representam apenas uma parcela dos casos efetivamente ocorridos. Como consequência, bases de dados relacionadas à violência frequentemente apresentam informações incompletas ou classificadas como ignoradas, dificultando a compreensão integral do fenômeno e a formulação de políticas públicas mais eficazes.

Além disso, a violência contra a mulher caracteriza-se por sua natureza multifatorial. Aspectos relacionados à idade da vítima, vínculo com o agressor, contexto familiar, uso de álcool ou drogas, reincidência da violência e condições socioeconômicas podem influenciar diretamente a ocorrência e a gravidade dos episódios registrados.

Apesar dos avanços legislativos e das políticas públicas implementadas nas últimas décadas, a violência contra a mulher permanece como um problema global. Dados divulgados pela ONU Mulheres indicam que aproximadamente 85 mil mulheres e meninas foram assassinadas intencionalmente em 2023, sendo que cerca de 60% desses casos foram praticados por parceiros íntimos ou familiares. O relatório também aponta que mais de 51 mil mulheres perderam a vida em decorrência da violência praticada por pessoas de seu convívio próximo, evidenciando a permanência da violência doméstica como uma das principais ameaças à segurança feminina.

Esses números demonstram que a violência contra a mulher permanece presente em diferentes regiões do mundo, independentemente do nível de desenvolvimento econômico ou das características culturais dos países. O cenário reforça a necessidade de estratégias preventivas

fundamentadas em evidências científicas capazes de identificar fatores de risco e orientar ações de proteção.

O crescimento da disponibilidade de bases públicas de dados possibilitou a aplicação de técnicas de Ciência de Dados e Aprendizado de Máquina na análise de fenômenos sociais complexos. No contexto da violência contra a mulher, essas ferramentas permitem identificar padrões ocultos, relações entre variáveis e fatores associados à ocorrência de diferentes tipos de agressão.

A análise de grandes volumes de dados provenientes de sistemas de notificação possibilita compreender características relacionadas ao perfil das vítimas, dos agressores e das circunstâncias em que os episódios de violência ocorrem. A partir dessas informações, algoritmos de classificação podem ser utilizados para estimar a probabilidade de ocorrência de determinados eventos e auxiliar processos de tomada de decisão.

Estudos recentes demonstram que técnicas de mineração de dados e aprendizado supervisionado apresentam potencial para apoiar políticas públicas, identificar grupos mais vulneráveis e contribuir para estratégias preventivas voltadas ao enfrentamento da violência de gênero. Nesse contexto, a integração entre inteligência artificial, saúde pública e segurança pública representa uma importante ferramenta para ampliar a compreensão do fenômeno e apoiar ações baseadas em evidências.

## **DESCRIÇÃO**

### **Macro visão do projeto e Metodologia empregada**

Este estudo caracteriza-se como uma pesquisa de abordagem quantitativa e qualitativa fundamentada em revisão bibliográfica e análise de dados estatísticos secundários. A pesquisa bibliográfica foi realizada com base em documentos oficiais, relatórios de organismos internacionais e nacionais, usando como base a Organização das Nações Unidas (ONU), o Fórum Brasileiro de Segurança Pública, o Instituto de Pesquisa Econômica Aplicada (IPEA), Senado Federal e o Instituto Maria da Penha (IMP).

Para a análise estatística principal, foram utilizados dados provenientes do Sistema de Informação de Agravos de Notificação, adaptados a partir de uma base pública disponibilizada

na plataforma Kaggle. A base foi utilizada para o tratamento, organização e análise exploratória dos registros, possibilitando a identificação de padrões relacionados aos tipos de violência, ao perfil das vítimas e às características associadas às notificações.

Inicialmente, realizou-se a etapa de coleta e seleção do dataset, seguida pelos processos de tratamento e limpeza dos dados, identificação e remoção de valores inconsistentes e transformação das variáveis categóricas. Posteriormente, foi conduzida a análise estatística exploratória, permitindo compreender a distribuição e o comportamento das variáveis presentes na base de dados.

Na etapa de modelagem, aplicaram-se técnicas de aprendizado de máquina supervisionado, com foco no treinamento e avaliação de modelos preditivos voltados à identificação de padrões associados aos casos de violência física contra mulheres no Brasil. Por fim, os resultados obtidos foram interpretados com o objetivo de contribuir para análises estatísticas mais aprofundadas e ampliar a compreensão do fenômeno social investigado.

### **Macro Visão do Dataset**

O conjunto de dados utilizado neste estudo é composto por aproximadamente de 161 colunas, abrangendo informações detalhadas sobre notificações de violência contra a mulher registradas no Sistema de Informação de Agravos de Notificação (SINAN). Essas variáveis incluem dados sociodemográficos, características da vítima, informações do agressor, tipos de violência, além de aspectos relacionados ao atendimento e encaminhamento dos casos.

Diante da elevada dimensionalidade do dataset, foi necessária a realização de um processo de seleção de variáveis com o objetivo de identificar os atributos mais relevantes para a análise estatística e para a futura etapa de modelagem preditiva.

Esse procedimento teve como objetivo reduzir a dimensionalidade do conjunto de dados, eliminar atributos redundantes ou pouco relevantes e concentrar a análise em variáveis com maior capacidade explicativa em relação ao fenômeno estudado.

### **Seleção e organização das variáveis**

As variáveis selecionadas foram organizadas em três principais eixos analíticos. O primeiro contempla o perfil sociodemográfico das vítimas, incluindo informações relacionadas à idade, sexo, raça, escolaridade, estado civil e ocupação. O segundo eixo corresponde às características da violência, abrangendo tipo de agressão, motivação, local de ocorrência e recorrência dos casos. Por fim, o terceiro eixo refere-se à relação entre vítima e agressor, considerando vínculos familiares, afetivos ou desconhecidos.

Diante dessa análise, foram selecionadas e organizadas as seguintes colunas com seus respectivos dados:

Tabela 1 – Seleção Variáveis

| Posição | Coluna          | Dtype   |
|---------|-----------------|---------|
| 0       | UF              | str     |
| 1       | ANO             | int64   |
| 2       | DT_NOTIFIC      | str     |
| 3       | DT_OCOR         | str     |
| 4       | DT_NASC         | str     |
| 5       | NU_IDADE_N      | float64 |
| 6       | CS_SEXO         | str     |
| 7       | CS_RACA         | float64 |
| 8       | CS_ESCOL_N      | float64 |
| 9       | SIT_CONJUG      | float64 |
| 10      | ID_OCUPA_N      | float64 |
| 11      | ORIENT_SEX      | int64   |
| 12      | IDENT_GEN       | int64   |
| 13      | CICL_VID        | int64   |
| 14      | LOCAL_OCOR<br>R | int64   |
| 15      | HORA_OCOR       | str     |

|    |            |         |
|----|------------|---------|
| 16 | OUT_VEZES  | float64 |
| 17 | VIOL_MOTIV | int64   |
| 18 | LES_AUTOP  | float64 |
| 19 | VIOL_FISIC | int64   |
| 20 | VIOL_PSICO | int64   |
| 21 | VIOL_TORT  | int64   |
| 22 | VIOL_SEXU  | int64   |
| 23 | VIOL_FINAN | int64   |
| 24 | VIOL_NEGLI | int64   |
| 25 | SEX_ASSEDI | float64 |
| 26 | SEX_ESTUPR | float64 |
| 27 | SEX_EXPLO  | float64 |
| 28 | SEX_PORNO  | float64 |
| 29 | SEX_OUTRO  | float64 |
| 30 | REL_PAI    | float64 |
| 31 | REL_MAE    | float64 |
| 32 | REL_PAD    | float64 |

|    |                |         |
|----|----------------|---------|
| 33 | REL_MAD        | float64 |
| 34 | REL_CONJ       | float64 |
| 35 | REL_EXCON      | float64 |
| 36 | REL_NAMO       | float64 |
| 37 | REL_EXNAM      | float64 |
| 38 | REL_FILHO      | float64 |
| 39 | REL_IRMAO      | float64 |
| 40 | REL_CONHE<br>C | float64 |
| 41 | REL_DESCO      | float64 |
| 42 | AUTOR_SEX<br>O | float64 |
| 43 | AUTOR_ALC<br>O | float64 |
| 44 | LESAO_NAT      | float64 |
| 45 | LESAO_CORP     | float64 |
| 46 | CLASSI_FIN     | float64 |
| 47 | EVOLUCAO       | float64 |
| 48 | ATEND_MUL      | float64 |

|    |                |         |
|----|----------------|---------|
| 49 | ASSIST_SOC     | float64 |
| 50 | DELEG_MUL<br>H | float64 |

Fonte: Elaborado pela autora (2026).

Durante o processo de preparação dos dados, algumas colunas foram renomeadas com o objetivo de tornar o dataframe mais compreensível e adequado às etapas de análise estatística e visualização gráfica. As variáveis “level\_0” e “level\_1” passaram a ser identificadas como “UF” e “ANO”, respectivamente. Com o objetivo de restringir a análise exclusivamente os casos de violência contra mulheres, foi aplicado um filtro utilizando a variável CS\_SEXO, selecionando apenas registros do sexo feminino (CS\_SEXO = 'F'). Além disso, foram removidos os registros classificados como lesão autoprovocada (LES\_AUTOP), garantindo que a análise permanecesse restrita aos casos de violência interpessoal.

### **Identificação e tratamento de dados faltantes**

Para identificação dos dados faltantes, foi realizado um print no qual mostrava a quantidade total de registros, diante disso foi gerada uma análise na qual mostrava quais colunas X quantidade de registros X percentual dos valores faltantes. Diante dessa validação, foi criado uma regra onde as colunas que tivessem mais de 40% de seus dados nulos, fossem removidas, exceto por algumas que foram definidas como essenciais para análise.

As colunas que apresentaram percentual elevado de valores ausentes e baixa relevância analítica foram removidas do estudo.

Tabela 2 – Colunas Excluídas

| Coluna     | Percentual<br>nulo |
|------------|--------------------|
| ID_OCUPA_N | 47                 |
| HORA_OCOR  | 55.20              |
| LESAO_NA   | 100                |
| LESAO_CORP | 100                |
| CLASSI_FIN | 100                |
| EVOLUCAO   | 100                |

Fonte: Elaborado pela autora

(2026).

Nesta etapa também foi criada a variável IDADE foi criada a partir da diferença entre as colunas DT\_OCOR e DT\_NASC, permitindo calcular a idade da vítima no momento da ocorrência, possibilitando análises mais detalhadas sobre a distribuição etária das vítimas quais serão as idades das vítimas que sofrem algum tipo de violência. Nesta etapa de criação da variável IDADE foi realizado o tratamento dos valores ausentes por meio da substituição pela mediana, visto que a mediana foi escolhida por ser menos sensível à presença de outliers por meio de outliers contidos no dataframe.

### **Tratamento de limpeza nos tipos Categóricos**

Nesta etapa, foi realizado o tratamento das variáveis categóricas com o objetivo de possibilitar análises estatísticas e compatibilidade com os algoritmos de Machine Learning. As variáveis categóricas foram convertidas para representações numéricas utilizando técnicas de codificação

apropriadas. As colunas categóricas são UF, ANO, CS\_RACA, CS\_ESCOL\_N e SIT\_CONJUG.

Tabela 3 – Colunas Categóricas

| Coluna         |
|----------------|
| UF             |
| ANO            |
| CS_RACA        |
| CS_ESCOL_<br>N |
| SIT_CONJU<br>G |

Fonte: Elaborado pela autora (2026).

### **Conversão de Booleanos para Inteiro**

Nesta etapa realizamos o tratamento de dados das colunas booleanas para inteiras, proporcionando maior consistência e padronização aos dados utilizados na modelagem em nossa análise. Dessa forma, como verificação final, citamos quais colunas ficaram com X dados para utilizarmos na nossa base.

### **Tratamento da Variável Alvo**

Nesta etapa, foi realizado o tratamento da variável alvo `VIOL\_FISIC`, responsável por indicar a ocorrência de violência física nos registros do Sistema de Informação de Agravos de Notificação. O processo teve como objetivo adequar os dados para utilização em modelos de

aprendizado de máquina supervisionado, garantindo maior consistência e confiabilidade durante a etapa de treinamento dos algoritmos.

Inicialmente, a variável foi convertida para formato numérico por meio da função `'pd.to_numeric()'`, utilizando o parâmetro `'errors='coerce'`, permitindo transformar valores inválidos em ausentes (`'NaN'`). Esse procedimento foi necessário devido à existência de registros inconsistentes e caracteres não numéricos presentes na base original. Posteriormente, aplicou-se o mapeamento oficial utilizado pelo SINAN para os registros de violência física, em que o valor `'1'` representa “Sim”, o valor `'2'` representa “Não” e o valor `'9'` corresponde a “Ignorado”. Considerando que os registros classificados como “Ignorado” não fornecem informação conclusiva para análise preditiva, esses dados foram removidos da base, mantendo apenas os casos válidos relacionados à ocorrência ou ausência de violência física.

Após a filtragem, a variável alvo foi transformada em formato binário, adequando-se ao contexto de classificação supervisionada. Dessa forma, os registros classificados originalmente como “Sim” foram convertidos para `'1'`, indicando ocorrência de violência física, enquanto os registros classificados como “Não” foram convertidos para `'0'`, representando ausência de violência física. Em seguida, foram removidos os valores ausentes restantes associados à variável alvo, evitando inconsistências durante o treinamento dos modelos. Por fim, realizou-se a conversão definitiva da variável para o tipo inteiro (`'int'`), assegurando compatibilidade com os algoritmos aplicados, como Árvore de Decisão, Regressão Logística e Random Forest. Esse tratamento foi fundamental para garantir que a variável alvo apresentasse apenas duas classes válidas e balanceadas para a modelagem preditiva, possibilitando a identificação de padrões associados à ocorrência de violência física contra mulheres no Brasil.

### **Separação das Variáveis Independentes e Dependentes**

Após a conclusão do tratamento da variável alvo, realizou-se a separação do conjunto de dados em variáveis independentes e variável dependente, etapa essencial para a construção dos modelos de aprendizado de máquina supervisionado. Nesse processo, a variável `VIOL_FISIC` foi definida como variável dependente ( $y$ ), representando o elemento que o modelo deveria prever, isto é, a ocorrência ou ausência de violência física.

As demais variáveis presentes na base foram utilizadas como variáveis independentes (X), funcionando como atributos preditores para identificação de padrões relacionados aos casos analisados. Entre essas variáveis encontram-se informações demográficas, sociais e contextuais, como idade da vítima, raça/cor, escolaridade, situação conjugal, local da ocorrência, relação entre vítima e agressor, uso de álcool pelo autor da agressão, entre outras características extraídas da base do Sistema de Informação de Agravos de Notificação.

A separação foi implementada por meio da criação de duas estruturas distintas no ambiente computacional: uma contendo exclusivamente a variável alvo (y) e outra contendo o conjunto de atributos preditivos (X). Esse procedimento permitiu organizar adequadamente os dados para as etapas posteriores de transformação, treinamento e avaliação dos modelos de classificação, garantindo maior controle sobre o processo de modelagem e evitando vazamento de informações entre as variáveis analisadas.

### **Conversão das Variáveis para Modelagem Numérica**

Após a separação entre variáveis independentes ('X') e variável dependente ('y'), realizou-se a etapa de conversão das variáveis para formato numérico, procedimento indispensável para aplicação dos algoritmos de aprendizado de máquina supervisionado. Essa transformação foi necessária porque grande parte dos modelos computacionais utilizados em classificação não realiza processamento direto de variáveis categóricas em formato textual.

Inicialmente, a variável 'UF' foi removida do conjunto destinado à modelagem preditiva, sendo mantida apenas para análises estatísticas e construção de gráficos exploratórios. Essa decisão foi adotada com o objetivo de evitar a criação excessiva de variáveis derivadas e reduzir possíveis interferências na capacidade de generalização dos modelos.

Na sequência, as variáveis categóricas restantes foram convertidas para representações numéricas utilizando a técnica de \*One-Hot Encoding\*, implementada por meio da função 'pd.get\_dummies()' da biblioteca 'Pandas'. Esse procedimento consiste em transformar cada categoria textual em colunas binárias independentes, assumindo valores '1' para presença da categoria e '0' para ausência. A aplicação dessa técnica possibilitou representar adequadamente atributos categóricos relacionados ao perfil das vítimas, local da ocorrência e características do agressor, garantindo compatibilidade com algoritmos de classificação como Árvore de Decisão,

Regressão Logística e Random Forest. Além da conversão categórica, os valores ausentes remanescentes foram preenchidos utilizando estratégias de imputação estatística, assegurando que todas as variáveis apresentassem formato exclusivamente numérico e sem inconsistências estruturais. Ao final dessa etapa, o conjunto de dados encontrava-se totalmente preparado para os processos de treinamento, validação e avaliação dos modelos preditivos.

### **Imputação Estatística dos Valores Ausentes**

Após a etapa de conversão das variáveis categóricas para formato numérico, realizou-se um procedimento complementar de tratamento dos valores ausentes remanescentes presentes no conjunto de dados. Essa etapa foi necessária para garantir que os algoritmos de aprendizado de máquina pudessem processar adequadamente todas as variáveis, uma vez que muitos modelos de classificação supervisionada não operam corretamente na presença de dados nulos ('NaN').

Para o tratamento dessas inconsistências, foi utilizada a técnica de imputação estatística por meio da classe 'SimpleImputer', pertencente à biblioteca 'Scikit-learn'. A estratégia adotada foi baseada na mediana ('strategy='median'), substituindo automaticamente os valores ausentes pelo valor mediano de cada variável numérica.

A escolha da mediana ocorreu devido à sua maior robustez estatística em relação à média aritmética, principalmente em bases de dados que apresentam distribuição assimétrica ou presença de valores extremos (\*outliers\*). Dessa forma, o procedimento contribuiu para minimizar distorções nos dados e preservar a distribuição original das variáveis utilizadas na modelagem preditiva.


Após a aplicação da imputação, os dados foram reorganizados em uma nova estrutura tabular, mantendo a integridade das colunas e garantindo alinhamento correto entre as variáveis independentes ('X') e a variável dependente ('y'). Em seguida, realizou-se uma validação final do conjunto de dados, verificando a inexistência de valores nulos remanescentes. Essa etapa foi fundamental para assegurar maior estabilidade computacional, qualidade estatística e compatibilidade do dataset com os modelos de classificação aplicados, como Árvore de Decisão, Regressão Logística e Random Forest.

## Análise Estatística e Exploratória

Com os dados devidamente tratados e estruturados, foram realizadas análises estatísticas e exploratórias com o objetivo de compreender o comportamento das variáveis presentes no dataset e identificar padrões associados à ocorrência de violência física contra mulheres no Brasil. Essa etapa possibilitou extrair informações relevantes sobre o perfil das vítimas, características dos agressores, distribuição geográfica dos casos e relação entre os diferentes tipos de violência registrados no Sistema de Informação de Agravos de Notificação.

Inicialmente, buscou-se compreender o perfil sociodemográfico das vítimas notificadas, considerando variáveis relacionadas à raça/cor, escolaridade e faixa etária.

Figura 1 – Distribuição das vítimas por raça



Identificação das principais raças de vítimas, sendo subdividas em parda, branca, preta, indígena, amarela e ignorado.


Fonte: Elaborado pela autora (2026).

A distribuição das vítimas segundo a classificação de raça/cor permite identificar a concentração de ocorrências em determinados grupos étnicos. Conforme ilustrado na Figura 1, observa-se uma predominância acentuada de vítimas autodeclaradas pardas e brancas. É relevante destacar, contudo, a incidência de registros classificados como "Ignorado", que totalizam aproximadamente 50.000 casos. Tal dado aponta para uma lacuna no preenchimento dos formulários oficiais, o que pode mascarar a real magnitude da violência em outros estratos raciais.

Em escala significativamente menor, figuram as notificações referentes a mulheres pretas, indígenas e amarelas. No caso específico das populações pretas e indígenas, a baixa representatividade numérica no gráfico confronta-se, muitas vezes, com a realidade de vulnerabilidade social, sugerindo a existência de subnotificação ou barreiras estruturais no acesso aos órgãos de registro e acolhimento.

Ademais, a análise da escolaridade das vítimas é um indicador crucial para compreender o contexto socioeconômico e o potencial de autonomia dessas mulheres. A distribuição dos registros segundo o nível de instrução formal é apresentada na Figura 2.

Figura 2 – Distribuição das vítimas por escolaridade



Distribuição das principais escolaridades das vítimas subdivididas em categorias de ensino do básico até o superior

Fonte: Elaborado pela autora (2026).


Ao examinar a Figura 2, observa-se que os resultados demonstram uma maior concentração de notificações entre vítimas com ensino superior completo, seguidas por aquelas com a 4ª série completa e ensino médio incompleto. Esse cenário revela uma ampla distribuição entre diferentes níveis educacionais, refutando a ideia de que a violência física estaria restrita a grupos com menor acesso à instrução formal.

A presença significativa de mulheres com escolaridade elevada no topo das estatísticas deste *dataset* sugere que o acesso à educação superior pode atuar como um facilitador para a formalização da denúncia e a busca por apoio institucional, embora não as isenta de situações de vulnerabilidade física.

Concluída a análise do nível instrucional, outra variável determinante para a compreensão do fenômeno é a faixa etária das vítimas, uma vez que a violência pode manifestar-se com

intensidades e características distintas ao longo dos diferentes ciclos de vida. A distribuição da idade das mulheres notificadas é apresentada na Figura 3.

Figura 3 – Distribuição da idade das Vítimas



Distribuição da idade das vítimas, identificando os picos de quais idades são mais recorrentes.


Fonte: Elaborado pela autora (2026).

A análise da Figura 3 revela uma concentração significativa de casos em mulheres jovens e adultas. Observa-se um pico proeminente de notificações na faixa que compreende os 10 aos 30 anos, com especial destaque para o intervalo entre os 20 e 25 anos, que apresenta o maior volume de ocorrências no dataset.

A partir dos 40 anos, nota-se uma tendência de declínio gradual e constante no número de notificações à medida que a idade avança. Este comportamento estatístico sugere que mulheres em idade reprodutiva e em fase de maior inserção social ou laboral compõem o grupo com maior número de registros de violência física. Por outro lado, o volume reduzido de notificações em idades avançadas pode indicar tanto uma redução real da incidência quanto uma maior dificuldade de acesso ou barreiras sociais para a denúncia por parte de mulheres idosas.

Após a caracterização do perfil sociodemográfico das vítimas, torna-se imperativo analisar as variáveis relacionadas aos agressores, a fim de compreender a dinâmica da violência sob a perspectiva de quem a pratica. Nesse sentido, a Figura 4 apresenta a distribuição dos autores conforme o sexo, permitindo identificar o gênero predominante nas notificações de violência física registradas.

Figura 4 – Distribuição da idade das Vítimas




Identificação das faixas etárias das vítimas criada a partir da variável idade

Fonte: Elaborado pela autora (2026).

A análise da Figura 4 revela uma concentração significativa de casos em mulheres jovens e adultas. Observa-se que o maior volume de ocorrências no dataset concentra-se na faixa de transição entre a juventude e a idade adulta (especialmente entre os 20 e 30 anos). A partir dos 40 anos, nota-se uma tendência de declínio gradual no número de notificações. Este comportamento sugere que mulheres em fase de maior inserção social e laboral apresentam maior índice de registros, enquanto o volume reduzido em idades avançadas pode indicar barreiras sociais ou dificuldades de acesso aos canais de denúncia por parte de mulheres idosas.

Após a caracterização do perfil sociodemográfico das vítimas, torna-se imperativo analisar as variáveis relacionadas aos agressores, a fim de compreender a dinâmica da violência sob a perspectiva de quem a pratica. Nesse sentido, a Figura 5 apresenta a distribuição dos autores conforme o sexo, permitindo identificar o gênero predominante nas notificações de violência física registradas.

Figura 5 – Sexo dos Autores da Violência




Identificação dos principais autores de violência, predominantemente o sexo masculino se destaca com cerca de 67,0%.

Fonte: Elaborado pela autora (2026).

Ao examinar a Figura 5, constata-se uma disparidade acentuada no perfil de gênero dos agressores. Os dados evidenciam que 67% dos atos de violência são perpetrados por indivíduos do sexo masculino, consolidando-os como os principais autores nas notificações analisadas. Em contrapartida, autoras do sexo feminino representam 15,9% dos casos, enquanto a categoria 'Ambos' totaliza 7%. É relevante destacar que 10,1% dos registros constam como 'Ignorado', o que aponta para lacunas na identificação do autor no momento da notificação. Esses resultados corroboram a literatura especializada, que relaciona a prevalência de agressores masculinos a estruturas patriarcais e desigualdades históricas de poder.

Além do perfil dos envolvidos, é fundamental analisar o comportamento temporal das notificações para verificar a progressão do fenômeno no período estudado. Nesse sentido, a Figura 6 apresenta a evolução anual dos casos registrados entre os anos de 2017 e 2019, permitindo observar a tendência de crescimento ou estabilidade das ocorrências.

Figura 6 – Total de Casos por Ano




Identificação dos anos com principais casos, se destacando a crescente entre o ano de 2017 a 2019.

Fonte: Elaborado pela autora (2026).

A análise da Figura 6 demonstra uma tendência de crescimento contínuo no número de notificações de violência física ao longo do triênio pesquisado. Observa-se que em 2017 o volume de casos situava-se próximo a 175.000, elevando-se para aproximadamente 185.000 em 2018 e atingindo o pico de quase 200.000 registros em 2019. Esse aumento progressivo pode ser interpretado tanto como um agravamento real da violência quanto como um reflexo do fortalecimento das redes de proteção e do encorajamento das vítimas em formalizar as denúncias através dos órgãos competentes.

Identificado o crescimento temporal das notificações em nível nacional, faz-se necessário espacializar esses dados para compreender como a violência se distribui geograficamente. Dessa forma, a Figura 7 apresenta a distribuição dos casos por [Estado/Região/Local], permitindo identificar as áreas com maiores índices de registros e que demandam atenção prioritária das políticas públicas.

Figura 7 – Total de Casos por Estado




Identificação  
gráfica dos  
casos por  
Estados.

Fonte: Elaborado pela autora (2026).

Ao observar a Figura 7, nota-se uma distribuição heterogênea das notificações pelo território nacional. O estado de São Paulo concentra o maior volume absoluto de registros, seguido por Minas Gerais e Rio de Janeiro. Esta concentração pode estar relacionada tanto à elevada densidade populacional desses centros urbanos quanto à maior capilaridade e eficácia dos sistemas de registro e redes de proteção locais, que favorecem a formalização das denúncias.

Dada a disparidade entre as unidades federativas, torna-se relevante destacar os estados que apresentam os índices mais críticos de notificações no período. Nesse sentido, a Figura 8 isola as dez unidades da federação com maior número de casos, permitindo uma visualização mais precisa das localidades que demandam uma alocação prioritária de recursos e políticas de enfrentamento à violência contra a mulher.

Figura 8 – Estados com Maior Número de Casos




Representação  
gráfica dos  
principais casos  
por Estados

Fonte: Elaborado pela autora (2026).

A análise da Figura 8 evidencia que o estado de São Paulo lidera isoladamente o ranking nacional, com um volume superior a 130.000 notificações — patamar significativamente mais elevado que o segundo colocado, Minas Gerais (aproximadamente 75.000). Observa-se que, além do Sudeste, estados das regiões Sul e Nordeste também figuram entre as maiores incidências. Esse detalhamento reforça a necessidade de estratégias regionais específicas, considerando que o volume acumulado apenas nesses dez estados representa a grande maioria dos registros totais do dataset.

Em contrapartida, para obter uma visão completa da heterogeneidade nacional, torna-se necessário observar o extremo oposto da distribuição. A Figura 9 apresenta as dez unidades da federação com os menores volumes de notificações registradas, permitindo analisar o comportamento do fenômeno em estados com diferentes densidades demográficas e estruturas de rede.

Figura 9 – Estados com Menor Número de Casos




Representação  
gráfica dos menores  
casos por Estados

Fonte: Elaborado pela autora (2026).

A partir da Figura 9, verifica-se que estados como Amapá, Roraima e Rondônia apresentam os menores números absolutos de casos no período analisado, com o Amapá registrando pouco mais de 1.000 ocorrências. É fundamental ressaltar que esses baixos índices não indicam, necessariamente, uma menor prevalência da violência nessas localidades, mas podem refletir a menor densidade populacional desses estados ou possíveis dificuldades estruturais na centralização das notificações. Esse contraste regional sublinha a necessidade de políticas descentralizadas e adaptadas às realidades de cada unidade federativa.

Para além da distribuição geográfica entre os estados, torna-se essencial identificar os espaços específicos onde esses atos de violência física são perpetrados. Compreender o cenário da ocorrência permite distinguir entre a violência doméstica e a violência urbana. Nesse sentido, a Figura 10 detalha os locais com maior incidência de registros, evidenciando os ambientes de maior vulnerabilidade para vítimas.

Figura 10 – Locais com Maior ocorrência de Violência




Identificação gráfica dos locais com maiores ocorrências de violência, se destacando a residência

Fonte: Elaborado pela autora (2026).

A análise da Figura 10 revela um dado alarmante que é amplamente discutido na literatura sobre violência de gênero: a residência aparece como o principal local de ocorrência, com um volume superior a 300.000 registros. A predominância do ambiente doméstico como palco da violência reafirma que, para a mulher, o lar muitas vezes constitui o espaço de maior risco, geralmente associado a agressores com quem a vítima possui laços afetivos. Em contrapartida, locais como a via pública, com cerca de 75.000 casos, e estabelecimentos comerciais apresentam frequências significativamente menores, reforçando o caráter intrafamiliar de grande parte das notificações.

Uma vez compreendidos o perfil dos envolvidos e o cenário onde os fatos ocorrem, resta analisar a natureza dessas agressões. A violência contra a mulher é um fenômeno multidimensional que pode se manifestar de diversas formas, desde danos psicológicos até agressões patrimoniais. Nesse sentido, a Figura 11 apresenta a frequência e recorrência dos principais tipos de violência registrados no dataset.

Figura 11 – Tipos de Violência Mais Frequentes




Identificação gráfica dos tipos de violência mais frequentes, se destacando disparado a violência física

Fonte: Elaborado pela autora (2026).

A análise da Figura 11 evidencia a predominância da violência física, que supera a marca de 350.000 notificações, seguida pelas violências psicológica e sexual. É imperativo destacar que, embora a violência física seja a mais visível nos registros oficiais, ela raramente ocorre de forma isolada, sendo frequentemente o ápice de um ciclo que envolve outros abusos menos explícitos, como a negligência e a violência financeira.

Para aprofundar a compreensão sobre a interdependência dessas variáveis, foram calculadas estatísticas descritivas das variáveis numéricas, incluindo medidas de tendência central e dispersão. Posteriormente, realizou-se a análise da variável IDADE por meio de Boxplot, permitindo identificar a presença de valores extremos na distribuição etária. Complementarmente, foi construída uma matriz de correlação utilizando o coeficiente de Pearson, possibilitando identificar as variáveis com maior relação com a variável alvo VIOL\_FISIC. O resultado desse cruzamento estatístico é apresentado na Figura 12.

Figura 12 – Correlação das variáveis com violência física




Correlação dos tipos de violência com a principal violência praticada, que é a física.

Fonte: Elaborado pela autora (2026).

Os resultados expostos na Figura 12 confirmam que as variáveis relacionadas à violência psicológica, tortura e violência financeira apresentam as maiores correlações positivas com a variável alvo (violência física). Em contrapartida, a variável idade apresenta uma correlação negativa, sugerindo que a incidência de notificações de agressão física tende a diminuir em faixas etárias mais elevadas dentro do conjunto de dados analisados.

Embora a análise individual em relação à violência física seja reveladora, a compreensão integral do fenômeno exige observar como todas as tipologias de abuso se relacionam simultaneamente. Para tanto, foi elaborada uma matriz de correlação abrangente, apresentada sob a forma de mapa de calor (heatmap). A Figura 13 permite identificar a força da associação entre as diferentes formas de agressão, revelando padrões de coexistência que caracterizam a complexidade da violência contra a mulher.

Figura 13 – Matriz de Correlação



Fonte: Elaborado pela autora (2026).


A matriz de correlação evidenciada na Figura 13 demonstra uma forte associação entre as diferentes formas de violência, especialmente entre a violência psicológica, a tortura e a violência financeira, cujos coeficientes indicam uma alta probabilidade de ocorrência conjunta. Notadamente, a relação entre violência psicológica e tortura destaca-se como uma das mais intensas no mapa de calor. Esses resultados sugerem a coexistência de múltiplos tipos de agressão nos registros analisados, reforçando que a violência física é, frequentemente, apenas um componente de um cenário de abusos múltiplos e crônicos.

### Verificação da Distribuição da Variável Alvo

Antes de submeter os dados ao treinamento dos modelos de aprendizagem de máquina, realizou-se a verificação da distribuição das classes da variável alvo VIOL\_FISIC. Essa etapa é fundamental para garantir a integridade do processo de aprendizado supervisionado, evitando que o modelo desenvolva tendenciosidades (bias) devido a um desequilíbrio extremo entre as categorias.

A Figura 14 apresenta a distribuição absoluta e percentual entre os casos classificados como violência física e não física no dataset.

Figura 14 – Distribuição da variável alvo VIOL\_FISIC.



Fonte: Elaborado pela autora (2026).

Conforme demonstrado na Figura 14, o conjunto de dados apresenta uma distribuição equilibrada entre as classes, com 54,6% dos registros correspondendo à ocorrência de violência física e 45,4% à ausência desta. A presença de um volume substancial de dados para-ambas as categorias da classificação binária asseguram que o modelo poderá aprender os padrões distintivos de cada classe com maior precisão, mitigando riscos de inconsistências durante a fase de validação e testes.

### **Modelagem Preditiva por Árvore de Decisão**


A modelagem preditiva consiste na aplicação de técnicas estatísticas e de aprendizado de máquina com o objetivo de identificar padrões presentes em conjuntos de dados históricos e utilizá-los para prever eventos futuros. No contexto deste trabalho, a modelagem foi empregada para estimar a ocorrência de violência física contra a mulher a partir das características registradas nas notificações analisadas.

Entre os algoritmos de classificação supervisionada disponíveis, destaca-se a Árvore de Decisão (Decision Tree), técnica amplamente utilizada em problemas de classificação devido à sua capacidade de interpretação e representação das regras de decisão. O algoritmo constrói uma estrutura hierárquica composta por nós de decisão e folhas de classificação, realizando sucessivas divisões dos dados com o objetivo de gerar subconjuntos cada vez mais homogêneos em relação à variável alvo. O processo de construção da árvore ocorre por meio da seleção dos atributos que apresentam maior capacidade de separar as classes analisadas. Para isso, são empregadas métricas estatísticas como a entropia e o ganho de informação, responsáveis por medir o grau de pureza dos subconjuntos gerados após cada divisão. Dessa forma, o modelo identifica automaticamente quais variáveis possuem maior relevância para o processo de classificação.

Neste estudo, a variável alvo utilizada foi VIOL\_FISIC, responsável por indicar a ocorrência ou não de violência física. As demais variáveis presentes na base de dados foram utilizadas como atributos preditores, permitindo ao algoritmo aprender padrões relacionados às características das vítimas, dos agressores e das circunstâncias das ocorrências registradas.

A utilização da Árvore de Decisão apresenta vantagens importantes em aplicações de mineração de dados, especialmente devido à facilidade de interpretação dos resultados e à capacidade de identificar relações entre variáveis de forma visual e intuitiva. Além disso, o algoritmo permite analisar a importância relativa dos atributos utilizados no processo de classificação, contribuindo para uma compreensão mais aprofundada dos fatores associados ao fenômeno estudado.

Figura 15 – Estrutura simplificada da Árvore de Decisão utilizada no modelo.



Fonte: Elaborado pela autora (2026).

A Figura 15 apresenta a estrutura simplificada da Árvore de Decisão utilizada para classificação da ocorrência de violência física. Observa-se que a variável relacionada à violência sexual foi identificada como o principal critério de separação dos registros, seguida por variáveis associadas à violência psicológica, negligência e tortura. Esses resultados indicam que diferentes formas de violência apresentam forte relação com a ocorrência de agressões físicas, permitindo ao modelo estabelecer regras de decisão interpretáveis e de fácil compreensão. A representação simplificada foi utilizada para fins de visualização, preservando os principais padrões identificados pelo algoritmo durante o processo de treinamento.

### **Protocolos e Testes**

Após a conclusão das etapas de seleção, limpeza, transformação e codificação dos dados, foi definido o protocolo experimental utilizado para avaliar os modelos de aprendizado de máquina destinados à predição da variável alvo VIOL\_FISIC, responsável por indicar a ocorrência ou não de violência física contra a mulher. O conjunto de dados final utilizado na modelagem apresentou 680 registros válidos e 69 variáveis preditoras após a aplicação da técnica de One-Hot Encoding, empregada para converter atributos categóricos em variáveis numéricas compatíveis com os algoritmos supervisionados. A distribuição da variável alvo demonstrou um comportamento relativamente equilibrado entre as classes, com 409 registros classificados como ausência de violência física (60,15%) e 271 registros classificados como ocorrência de violência física (39,85%), conforme apresentado na Tabela 4.

Tabela 4 – Distribuição da variável alvo (VIOL\_FISIC)

| Classe                         | Quantidade | Percentual (%) |
|--------------------------------|------------|----------------|
| Ausência de violência física   | 409        | 60,15          |
| Ocorrência de violência física | 271        | 39,85          |
| Total                          | 680        | 100            |

Fonte: Elaborado pela autora (2026).

Para a realização dos experimentos, os dados foram divididos de forma estratificada em conjuntos de treinamento e teste por meio da função `train_test_split()`, preservando a proporção original das classes da variável alvo. Foi adotada a proporção de 70% dos registros para treinamento, correspondente a 476 observações, e 30% para teste, totalizando 204 observações.

Com o objetivo de garantir a reprodutibilidade dos experimentos computacionais, foi utilizado o parâmetro `random_state = 42` em todas as etapas de treinamento e avaliação dos modelos. Adicionalmente, para os algoritmos sensíveis à escala dos atributos, especialmente a Regressão Logística, aplicou-se a técnica de padronização das variáveis numéricas por meio do método `StandardScaler`, ajustando os dados para média igual a zero e desvio padrão unitário.

Foram avaliados três algoritmos supervisionados amplamente empregados em problemas de classificação binária: Árvore de Decisão (Decision Tree), Regressão Logística (Logistic Regression) e Random Forest. A seleção desses modelos fundamentou-se na ampla utilização em tarefas de mineração de dados, interpretabilidade dos resultados e capacidade de identificação de padrões em bases de dados complexas.

As principais configurações adotadas durante os experimentos encontram-se apresentadas na Tabela 5.

Tabela 5 – Configuração dos algoritmos utilizados nos experimentos

| <b>Algoritmo</b>    | <b>Principais Configurações</b>          |
|---------------------|------------------------------------------|
| Árvore de Decisão   | criterion = entropy; max_depth = 5       |
| Regressão Logística | class_weight = balanced; max_iter = 1000 |
| Random Forest       | n_estimators = 200; max_depth = 15       |
| Divisão dos Dados   | 70% treinamento; 30% teste               |
| Reprodutibilidade   | random_state = 42                        |

Fonte: Elaborado pela autora (2026).

A avaliação dos modelos foi realizada por meio de métricas clássicas de classificação supervisionada, incluindo acurácia, precisão (precision), revocação (recall), F1-Score, matriz de confusão, Curva ROC (Receiver Operating Characteristic) e métrica AUC (Area Under the Curve). Essas métricas permitiram analisar de forma abrangente a capacidade preditiva dos algoritmos, bem como comparar seu desempenho na identificação da ocorrência de violência física. Além disso, foi realizada uma análise de importância das variáveis (Feature Importance), possibilitando identificar os atributos com maior influência nas previsões realizadas pelos modelos.

### **Testes Realizados**

Após a definição do protocolo experimental, os modelos de Árvore de Decisão, Regressão Logística e Random Forest foram treinados utilizando o conjunto de treinamento composto por 476 registros. Em seguida, os modelos foram aplicados ao conjunto de teste, contendo 204

registros não utilizados durante a fase de aprendizado, permitindo avaliar sua capacidade de generalização sobre dados desconhecidos.

Inicialmente, foram realizadas previsões da variável alvo VIOL\_FISIC para cada um dos modelos avaliados. As classificações obtidas foram comparadas aos valores reais presentes na base de teste, possibilitando o cálculo das métricas de desempenho definidas no protocolo experimental.

Na sequência, foram geradas as matrizes de confusão de cada algoritmo, permitindo identificar a quantidade de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos produzidos pelos modelos. Essa análise possibilitou avaliar não apenas a quantidade total de classificações corretas, mas também os tipos de erros cometidos durante o processo preditivo.

Posteriormente, foram calculadas as métricas de acurácia, precisão (precision), revocação (recall) e F1-Score, amplamente utilizadas na avaliação de modelos de classificação supervisionada. Essas métricas permitiram comparar o desempenho dos algoritmos sob diferentes perspectivas, considerando tanto a capacidade de identificar corretamente os casos positivos quanto o equilíbrio entre sensibilidade e precisão das previsões.

Além das métricas tradicionais de classificação, foi realizada a análise da Curva ROC (Receiver Operating Characteristic) e do indicador AUC (Area Under the Curve). Essas técnicas foram empregadas para avaliar a capacidade discriminativa dos modelos na separação entre registros classificados como ocorrência e ausência de violência física.

Por fim, foi conduzida uma análise de importância das variáveis (Feature Importance) utilizando o modelo Random Forest. Essa etapa teve como objetivo identificar os atributos com maior contribuição para o processo de classificação, permitindo compreender quais características apresentaram maior influência na previsão da ocorrência de violência física contra a mulher.

## Resultados dos Testes

Tabela 6 – Comparação dos modelos avaliados

| <b>Modelo</b>          | <b>Acurácia</b> | <b>Precisão<br/>(Classe<br/>Positiva)</b> | <b>Recall</b> | <b>F1-<br/>Score</b> | <b>ROC<br/>AUC</b> |
|------------------------|-----------------|-------------------------------------------|---------------|----------------------|--------------------|
| Árvore de<br>Decisão   | 93,14%          | 0,89                                      | 0,94          | 0,92                 | -                  |
| Regressão<br>Logística | 92,65%          | 0,88                                      | 0,94          | 0,91                 | -                  |
| Random Forest          | 94,61%          | 0,93                                      | 0,94          | 0,93                 | 0,9867             |

Fonte: Elaborado pela autora (2026).

Os experimentos realizados permitiram avaliar o desempenho dos modelos de Árvore de Decisão, Regressão Logística e Random Forest na predição da variável VIOL\_FISIC. Os resultados obtidos para as principais métricas de classificação são apresentados na Tabela 6.


Tabela 7 – Comparação dos modelos avaliados

| <b>Modelo</b>       | <b>Acurácia</b> | <b>Precisão</b> | <b>Recall</b> | <b>F1-Score</b> |
|---------------------|-----------------|-----------------|---------------|-----------------|
| Árvore de Decisão   | 0,9314          | 0,89            | 0,94          | 0,92            |
| Regressão Logística | 0,9265          | 0,88            | 0,94          | 0,91            |
| Random Forest       | 0,9461          | 0,93            | 0,94          | 0,93            |

Fonte: Elaborado pela autora (2026).

Conforme observado, todos os modelos apresentaram desempenho superior a 92% de acurácia, com destaque para o algoritmo Random Forest, que alcançou o maior valor entre os modelos avaliados.


A Figura 16 apresenta a matriz de confusão obtida pela Árvore de Decisão. O modelo classificou corretamente 114 registros pertencentes à classe negativa e 76 registros pertencentes à classe positiva, totalizando 190 classificações corretas em um conjunto de 204 observações.



Fonte: Elaborado pela autora (2026).

A Figura 17 apresenta a matriz de confusão correspondente à Regressão Logística. O modelo registrou 114 verdadeiros negativos, 76 verdadeiros positivos, 10 falsos positivos e 5 falsos negativos.


Figura 17 – Matriz de Confusão da Regressão Logística



Fonte: Elaborado pela autora (2026).

A Figura 18 apresenta os resultados obtidos pelo algoritmo Random Forest. Foram observados 117 verdadeiros negativos, 76 verdadeiros positivos, 6 falsos positivos e 5 falsos negativos, correspondendo ao melhor desempenho geral entre os modelos avaliados.


Figura 18 – Matriz de Confusão do Random Forest



Fonte: Elaborado pela autora (2026).

A capacidade discriminativa do modelo Random Forest também foi avaliada por meio da Curva ROC, apresentada na Figura 19. O modelo alcançou valor de AUC igual a 0,9867, indicando elevado desempenho na distinção entre registros com ocorrência e ausência de violência física.

Figura 19 – Curva ROC do modelo Random Forest



Identificação da  
curva ROC da  
Árvore de Decisão

Fonte: Elaborado pela autora (2026).

Adicionalmente, foi realizada uma análise de importância das variáveis (Feature Importance) utilizando o modelo Random Forest. As dez variáveis com maior contribuição para o processo de classificação são apresentadas na tabela 7.


Tabela 8 – Dez variáveis mais importantes para a predição da violência física

| <b>Variável</b> | <b>Importância</b> |
|-----------------|--------------------|
| SEX_OUTRO       | 0,1407             |
| SEX_ESTUPR      | 0,1379             |
| SEX_PORNO       | 0,1184             |
| SEX_EXPLO       | 0,1067             |
| VIOL_SEXU       | 0,106              |
| SEX_ASSEDI      | 0,0873             |
| IDADE           | 0,066              |
| NU_IDADE_N      | 0,0581             |
| REL_NAMO        | 0,0201             |
| VIOL_PSICO      | 0,0197             |

Fonte: Elaborado pela autora (2026).

A Figura 20 apresenta a representação gráfica da importância das variáveis identificadas pelo modelo Random Forest.

Figura 20 –Importância das Variáveis (Feature Importance)



Identificação das 10 das variáveis mais importantes do estudo, de acordo com o tratamento de dados

Fonte: Elaborado pela autora (2026).

## Análise dos Resultados

Os resultados obtidos demonstram que os três modelos supervisionados avaliados apresentaram elevado desempenho na predição da ocorrência de violência física contra a mulher. As acurácias observadas foram superiores a 92% em todos os algoritmos testados, evidenciando que os atributos presentes na base de dados possuem forte capacidade explicativa em relação à variável alvo VIOL\_FISIC.

Entre os modelos avaliados, o algoritmo Random Forest apresentou o melhor desempenho geral, alcançando acurácia de 94,61% e valor de ROC AUC igual a 0,9867. Esse resultado sugere excelente capacidade discriminativa do modelo na distinção entre registros classificados como ocorrência e ausência de violência física. O desempenho superior do Random Forest pode ser atribuído à sua estrutura baseada na combinação de múltiplas árvores de decisão, reduzindo problemas de variância e aumentando a robustez do processo classificatório quando comparado aos modelos individuais.

Embora a Árvore de Decisão tenha apresentado desempenho ligeiramente inferior ao Random Forest, sua acurácia de 93,14% demonstra que as relações existentes entre as variáveis

analisadas podem ser representadas por regras de decisão relativamente simples e interpretáveis. Já a Regressão Logística alcançou acurácia de 92,65%, evidenciando que mesmo um modelo estatístico linear foi capaz de identificar padrões relevantes associados à ocorrência de violência física.

Outro aspecto relevante refere-se à análise dos erros de classificação. O Random Forest registrou apenas cinco falsos negativos, indicando que a maior parte dos casos reais de violência física foi corretamente identificada pelo modelo. Em aplicações relacionadas à violência contra a mulher, essa característica é particularmente importante, pois falsos negativos representam situações em que ocorrências reais de violência poderiam deixar de ser reconhecidas. Dessa forma, o elevado valor de Recall obtido pelo modelo demonstra sua eficiência na identificação dos registros positivos da variável alvo.

A análise de importância das variáveis revelou que fatores associados à violência sexual e psicológica exerceram forte influência sobre a ocorrência de violência física. Entre os atributos mais relevantes destacaram-se as variáveis SEX\_OUTRO, SEX\_ESTUPR, SEX\_PORNO, SEX\_EXPLO, VIOL\_SEXU e VIOL\_PSICO. Esses resultados indicam que diferentes formas de violência tendem a ocorrer simultaneamente, reforçando a compreensão da violência contra a mulher como um fenômeno complexo e multifacetado.

Os resultados encontrados estão alinhados com estudos presentes na literatura, que apontam a coexistência de diferentes tipos de violência em relações marcadas por abuso e controle. A forte relevância das variáveis relacionadas à violência sexual e psicológica sugere que tais manifestações podem atuar como importantes indicadores da ocorrência de agressões físicas, evidenciando a necessidade de abordagens integradas de prevenção e assistência às vítimas.

Além disso, a presença das variáveis IDADE e NU\_IDADE\_N entre os principais fatores preditivos corrobora os achados observados durante a análise exploratória dos dados, indicando que a vulnerabilidade à violência física pode variar de acordo com a faixa etária das vítimas. Da mesma forma, a relevância da variável REL\_NAMO evidencia a influência dos relacionamentos afetivos na dinâmica das ocorrências registradas, aspecto frequentemente destacado em pesquisas sobre violência doméstica e violência de gênero.

De forma geral, os resultados demonstram que técnicas de aprendizado de máquina podem atuar como ferramentas eficazes para a identificação de padrões associados à violência contra a mulher, contribuindo para análises preditivas e para a geração de conhecimento capaz de subsidiar ações de prevenção, monitoramento e formulação de políticas públicas voltadas à proteção das vítimas.

## CONSIDERAÇÕES FINAIS

Este trabalho teve como objetivo analisar registros de violência contra a mulher e desenvolver modelos preditivos capazes de estimar a ocorrência de violência física a partir das características presentes nas notificações analisadas. Para isso, foram aplicadas técnicas de pré-processamento de dados, análise exploratória e aprendizado de máquina supervisionado, utilizando informações provenientes de registros oficiais de violência.

Durante a etapa de preparação dos dados, foram realizadas atividades de limpeza, tratamento de valores ausentes, transformação de variáveis categóricas, criação de novos atributos e adequação da base para utilização em algoritmos de classificação. Após essas etapas, obteve-se um conjunto de dados estruturado, composto por 680 registros válidos e 69 atributos preditores, permitindo a construção dos modelos de aprendizado de máquina.

A análise exploratória possibilitou identificar características relevantes associadas aos casos de violência física, evidenciando a influência de fatores relacionados ao perfil das vítimas, ao vínculo com o agressor e à presença simultânea de outras formas de violência. Os resultados demonstraram a importância da exploração inicial dos dados para compreender os padrões existentes nas notificações analisadas e subsidiar as etapas posteriores de modelagem preditiva.

Na etapa de modelagem, foram avaliados os algoritmos Árvore de Decisão, Regressão Logística e Random Forest. Todos os modelos apresentaram desempenho satisfatório, alcançando acurácia superior a 92%, o que demonstra a capacidade dos métodos supervisionados em identificar padrões associados à ocorrência de violência física. Entre os algoritmos avaliados, o Random Forest apresentou os melhores resultados, alcançando acurácia de 94,61% e valor de ROC AUC igual a 0,9867, evidenciando elevada capacidade discriminativa e robustez preditiva.

A análise de importância das variáveis revelou que atributos relacionados à violência sexual, violência psicológica, idade da vítima e relacionamento com o agressor exerceram forte influência no processo de classificação. Esses resultados reforçam a natureza multifatorial da violência contra a mulher e corroboram evidências apresentadas na literatura especializada, que aponta a coexistência de diferentes formas de violência em um mesmo contexto de vulnerabilidade.

Dessa forma, conclui-se que as técnicas de mineração de dados e aprendizado de máquina mostraram-se eficazes para a identificação de padrões associados à violência física contra a mulher, contribuindo para a geração de conhecimento e para o apoio à tomada de decisões em ações de prevenção e enfrentamento da violência. Os resultados obtidos demonstram o potencial dessas abordagens como ferramentas complementares para análise de dados públicos, monitoramento de fatores de risco e apoio à formulação de políticas públicas voltadas à proteção das mulheres.

Além disso, o estudo evidencia que a utilização de técnicas de Ciência de Dados pode contribuir significativamente para a compreensão de fenômenos sociais complexos, permitindo transformar grandes volumes de dados em informações úteis para pesquisadores, gestores públicos e instituições de apoio às vítimas. Nesse contexto, os modelos desenvolvidos representam uma alternativa promissora para auxiliar processos de análise e prevenção da violência de gênero.

Como limitação deste estudo, destaca-se a utilização de registros provenientes de um único estado e período temporal específico, o que pode restringir a generalização dos resultados para outras regiões do país. Adicionalmente, a qualidade das previsões está diretamente relacionada à completude e consistência das informações registradas nas bases de notificação utilizadas.

Como trabalhos futuros, recomenda-se a ampliação da base de dados com registros de diferentes estados e períodos temporais, a aplicação de técnicas de validação cruzada e balanceamento de classes, bem como a avaliação de outros algoritmos de aprendizado de máquina, incluindo métodos de Gradient Boosting e Redes Neurais Artificiais. Também se sugere o desenvolvimento de sistemas de apoio à decisão capazes de utilizar os modelos preditivos em ambientes reais de monitoramento e prevenção da violência contra a mulher.

## REFERÊNCIAS BIBLIOGRÁFICAS

BRASIL. Senado Federal. Pesquisa nacional de violência contra a mulher – DataSenado 2025. Brasília, DF, 2025. Disponível em: <https://www12.senado.leg.br/institucional/datasenado/materias/pesquisas/pesquisa-nacional-de-violencia-contra-a-mulher-datasenado-2025> . Acesso em: 10 maio 2026.

INSTITUTO MARIA DA PENHA. Resumo da Lei Maria da Penha. Fortaleza, [s.d.]. Disponível em: <https://www.institutomariadapenha.org.br/lei-11340/resumo-da-lei-maria-da-penha.html> . Acesso em: 10 maio 2026.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). Declaration on the Elimination of Violence against Women. New York, 1993. Disponível em: <https://www.ohchr.org/en/instruments-mechanisms/instruments/declaration-elimination-violence-against-women> . Acesso em: 10 maio 2026.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). ONU Mulheres; UNITED NATIONS OFFICE ON DRUGS AND CRIME (UNODC). Femicides in 2023: Global Estimates of Intimate Partner/Family Member Femicides. New York, 2024. Disponível em: <https://www.unwomen.org> . Acesso em: 10 maio 2026.

SCHRAIBER, Lília Blima; D'OLIVEIRA, Ana Flávia Pires Lucas; FRANÇA JUNIOR, Ivan; STRAKE, Silvia Soares; OLIVEIRA, Elaine de. A violência contra mulheres: demandas espontâneas e busca ativa em unidade básica de saúde. Saúde e Sociedade, São Paulo, v. 9, n. 1-2, p. 3-15, 2000.

ROSA, Tissiana. Estudo sobre a violência contra a mulher no Brasil. Kaggle, [S.l.], [s.d.]. Disponível em: <https://www.kaggle.com/code/tissianarosa/estudo-sobre-a-viol-ncia-contra-a-mulher-brasil> . Acesso em: 10 maio 2026.

BRASIL. Senado Federal. Observatório da Mulher contra a Violência. Violência contra a mulher 2025. Brasília, DF, 2025. Disponível em: [https://www12.senado.leg.br/institucional/omv/pdfs/info\\_pes\\_-violencia-contra-a-mulher\\_2025\\_digital.pdf](https://www12.senado.leg.br/institucional/omv/pdfs/info_pes_-violencia-contra-a-mulher_2025_digital.pdf) . Acesso em: 10 maio 2026.

BRASIL. Senado Federal. Anuário da ONU revela aumento da violência contra a mulher em todos os continentes. Brasília, DF, 2024. Disponível em:

<https://www12.senado.leg.br/radio/1/noticia/2024/11/25/anuario-da-onu-revela-aumento-da-violencia-contr-a-mulher-em-todos-os-continente> . Acesso em: 10 maio 2026.